IBM Developer
SKILLS NETWORK

Winning Space Race with Data Science

Murillo Massaharu Adachi

6 de novembro de 2026



Sumário

1 Resumo Executivo

2 Introdução

3 Metodologia

4 Resultados

5 Conclusão

6 Apêndice

Resumo Executivo

Resumo das metodologias

- Coleta de dados: API REST da SpaceX e web scraping da Wikipedia
- Data wrangling com pandas e criação da variável-alvo (Class)
- EDA com visualização de dados e SQL
- Analítica interativa: mapa Folium e dashboard Plotly Dash
- Classificação: Regressão Logística, SVM, Árvore de Decisão e KNN

Resumo dos resultados

- A taxa de sucesso do pouso cresce com o número de voos e ao longo dos anos
- KSC LC-39A é o local com maior taxa de sucesso
- Órbitas ES-L1, GEO, HEO e SSO tiveram 100% de sucesso (poucas amostras)
- Os quatro modelos atingiram cerca de 83% de acurácia no conjunto de teste

Introdução

Contexto

- A SpaceX oferece lançamentos do Falcon 9 por cerca de US$ 62 milhões; concorrentes cobram mais de US$ 165 milhões
- A economia vem da reutilização do primeiro estágio

Problema

- Se soubermos prever se o primeiro estágio vai pousar, podemos estimar o custo do lançamento
- Útil para uma empresa que queira competir com a SpaceX

Perguntas

- Quais fatores determinam o sucesso do pouso?
- Como carga, órbita, local e nº de voos se relacionam com o resultado?
- Quais condições garantem um pouso bem-sucedido?

A Jornada do Projeto

1 · Coleta

Pergunta: De onde vêm os dados?

Resposta: API da SpaceX e web scraping da Wikipedia

2 · Preparação

Pergunta: O que é um pouso bem-sucedido?

Resposta: Variável-alvo Class (0 ou 1)

3 · Exploração

Pergunta: O que os dados revelam?

Resposta: EDA com gráficos e SQL

4 · Geografia e interação

Pergunta: Onde e como lançam?

Resposta: Mapa Folium e dashboard Dash

5 · Modelagem

Pergunta: Dá para prever o pouso?

Resposta: Quatro modelos de classificação

6 · Decisão

Pergunta: O que fazer com isso?

Resposta: Estimar o custo e apoiar decisões

Section 1

Methodology



Metodologia

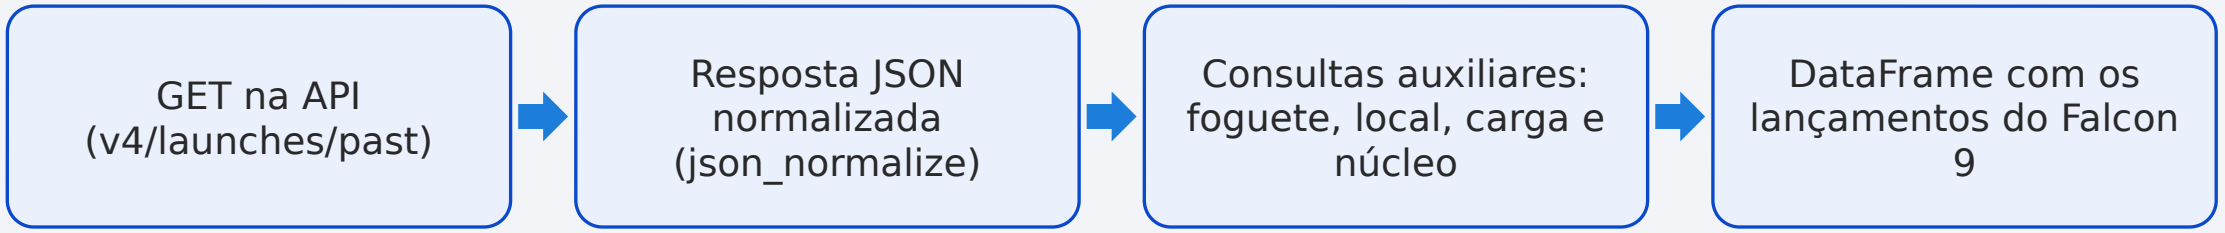
Resumo

- Metodologia de coleta de dados
  - API REST da SpaceX e web scraping de tabelas da Wikipedia
- Data wrangling
  - Tratamento de dados ausentes e criação da variável-alvo (Class)
- Análise exploratória (EDA) com visualização e SQL
- Analítica visual interativa com Folium e Plotly Dash
- Análise preditiva com modelos de classificação
  - Construção, ajuste (GridSearchCV) e avaliação dos modelos

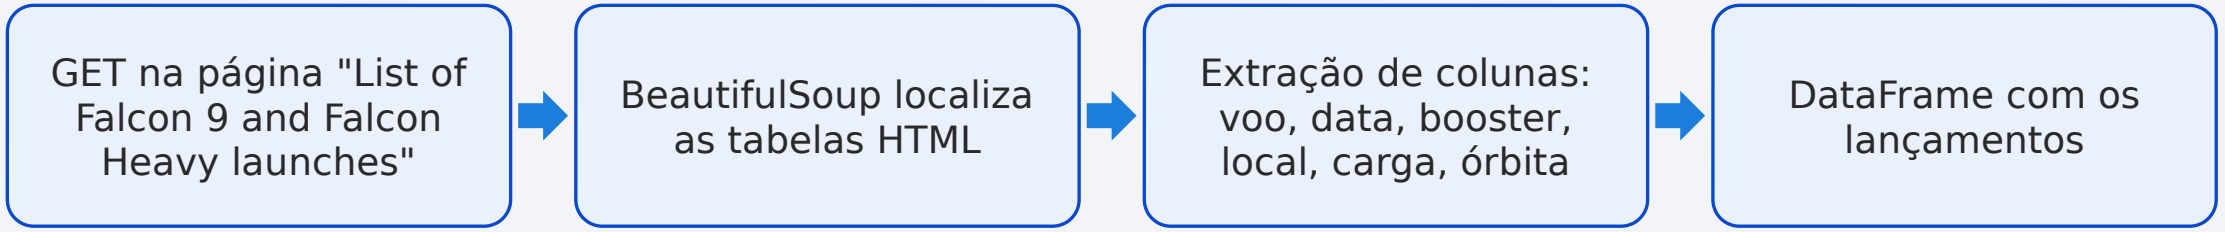
Coleta de Dados

Os dados foram coletados de duas fontes complementares, cada uma com seu fluxo:

API REST da SpaceX



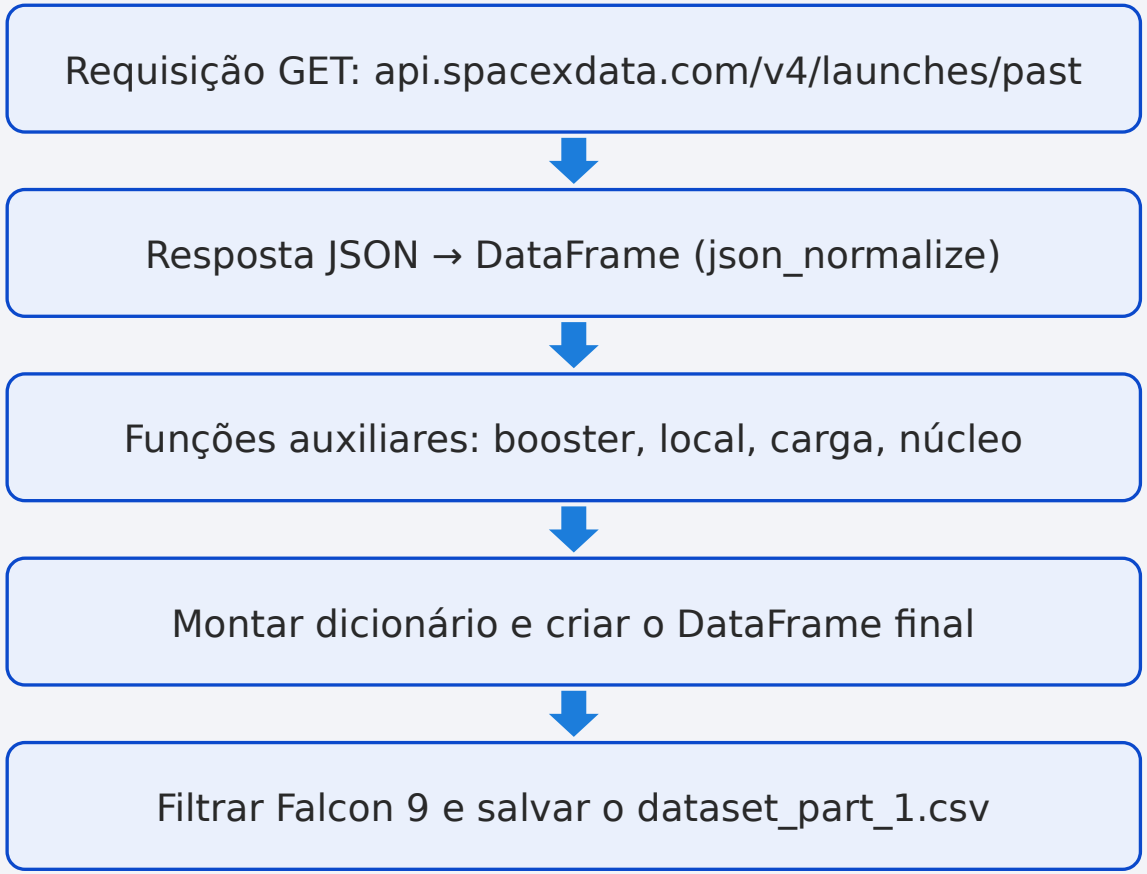
Web scraping (Wikipedia)



Resultado: um dataset consolidado de lançamentos do Falcon 9, pronto para o wrangling.

Coleta de Dados – API da SpaceX

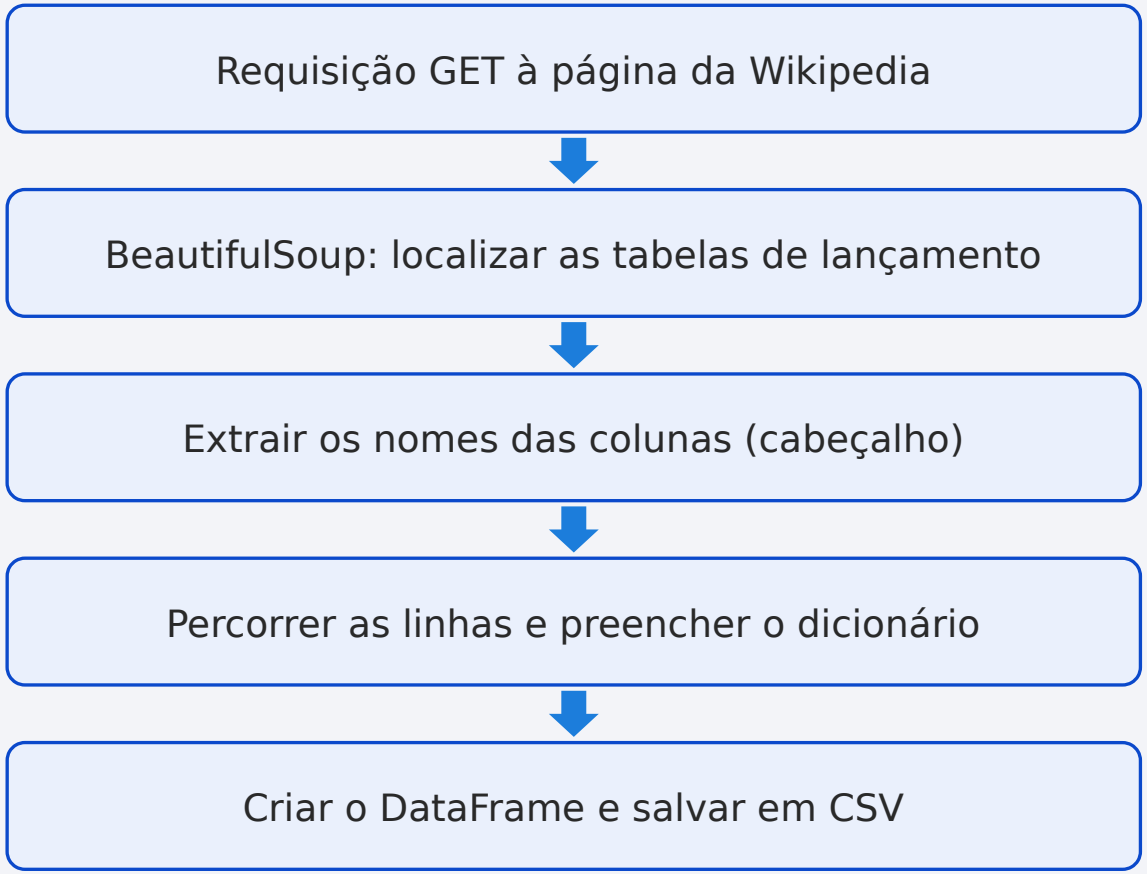
- Requisições REST à API da SpaceX (GET /v4/launches/past)
- Dados normalizados com json_normalize e enriquecidos por funções auxiliares
- Mantidos apenas lançamentos do Falcon 9 (sem Falcon 1), gerando o dataset_part_1.csv



GitHub: https://github.com/mmadachi/capstone-spacex/blob/main/notebooks/01_coleta_api_spacex.ipynb

Coleta de Dados – Web Scraping

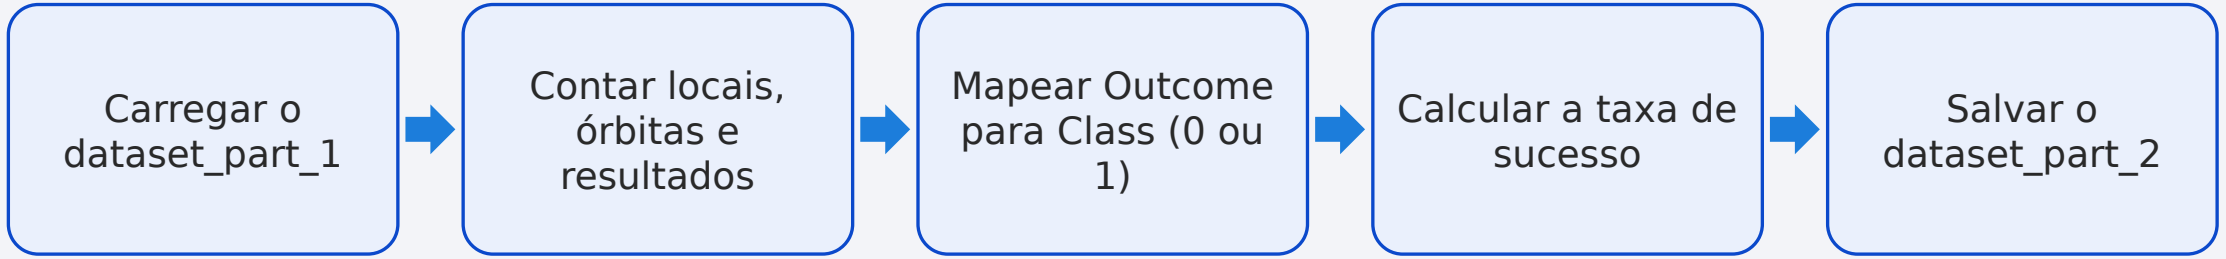
- Tabelas HTML de lançamentos extraídas da Wikipedia com requests e BeautifulSoup
- Cada linha da tabela vira um registro com voo, data, booster, local, carga, órbita e resultado
- DataFrame salvo como spacex_web_scraped.csv



GitHub: https://github.com/mmadachi/capstone-spacex/blob/main/notebooks/02_coleta_web_scraping.ipynb

Data Wrangling

- Contagem de lançamentos por local, por órbita e por tipo de resultado de pouso
- Resultados "ruins" (False Ocean, False RTLS, False ASDS, None ASDS, None None) recebem Class = 0; os demais, Class = 1
- A variável-alvo Class mostra taxa média de sucesso de 66,7% (60 de 90 lançamentos)



GitHub: https://github.com/mmadachi/capstone-spacex/blob/main/notebooks/03_data_wrangling.ipynb

EDA com Visualização de Dados

Dispersão (scatter)	Nº do voo e carga útil × local e × órbita. Mostram como variáveis numéricas se relacionam com categorias, com cor por resultado
Barras	Taxa de sucesso por tipo de órbita. Compara categorias de forma direta
Linha	Taxa de sucesso média por ano. Evidencia a tendência ao longo do tempo
Feature engineering	One-hot encoding de Orbit, LaunchSite, LandingPad e Serial, preparando as variáveis para o modelo

GitHub: https://github.com/mmadachi/capstone-spacex/blob/main/notebooks/05_eda_visualizacao.ipynb

EDA com SQL

- **Locais únicos** – SELECT DISTINCT
- **5 registros com local "CCA%"** – LIKE, LIMIT
- **Carga total da NASA** – SUM
- **Carga média do F9 v1.1** – AVG
- **Primeiro pouso em solo** – MIN

- **Drone ship com carga 4.000–6.000 kg** – BETWEEN
- **Missões por resultado** – GROUP BY, COUNT
- **Boosters com carga máxima** – subconsulta com MAX
- **Falhas em drone ship em 2015** – filtro por ano
- **Ranking de resultados de pouso** – ORDER BY DESC

GitHub: https://github.com/mmadachi/capstone-spacex/blob/main/notebooks/04_eda_sql.ipynb

Mapa Interativo com Folium

Círculos e marcadores	Posicionam cada local de lançamento (e o NASA JSC) no mapa, com rótulo, para dar contexto geográfico
MarkerCluster verde/vermelho	Mostra cada lançamento com sucesso (verde) ou falha (vermelho) sem poluir o mapa
MousePosition	Captura as coordenadas de costa, ferrovia, rodovia e cidade mais próximas
PolyLine e distância	Liga o local ao ponto de interesse e exibe a distância calculada (Haversine)

GitHub: https://github.com/mmadachi/capstone-spacex/blob/main/notebooks/06_mapa_folium.ipynb

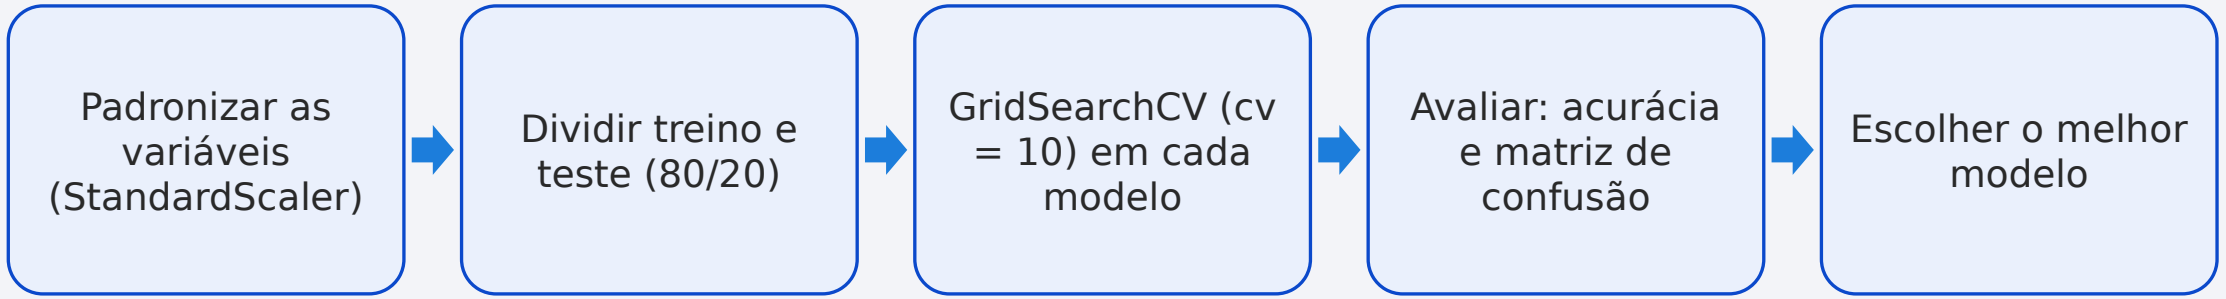
Dashboard com Plotly Dash

Dropdown de local	Filtra o painel por local de lançamento (todos ou um específico)
Gráfico de pizza	Mostra os sucessos por local e a razão sucesso × falha do local escolhido
Slider de carga útil	Permite explorar como a faixa de carga (0 a 10.000 kg) afeta o resultado
Dispersão carga × resultado	Colorida por versão do booster, compara o sucesso entre versões e faixas de carga
Callbacks	Ligam os controles aos gráficos e os atualizam de forma interativa

GitHub: https://github.com/mmadachi/capstone-spacex/blob/main/dashboard/spacex_dash_app.py

Análise Preditiva (Classificação)

- Quatro algoritmos treinados e comparados: Regressão Logística, SVM, Árvore de Decisão e KNN
- Hiperparâmetros ajustados com GridSearchCV (cv = 10); desempenho medido no conjunto de teste



GitHub: https://github.com/mmadachi/capstone-spacex/blob/main/notebooks/07_classificacao.ipynb

Resultados

Resultados da EDA

- Sucesso cresce com nº de voos e com o tempo
- KSC LC-39A lidera; órbitas SSO, GEO, HEO e ES-L1 com 100%

Analítica interativa

- Mapa: locais perto da costa e longe de cidades
- Dashboard: KSC LC-39A com 76,9% de sucesso

Análise preditiva

- Quatro modelos com 83,3% de acurácia no teste
- Matriz de confusão: 12 acertos nos pousos e 3 falsos positivos

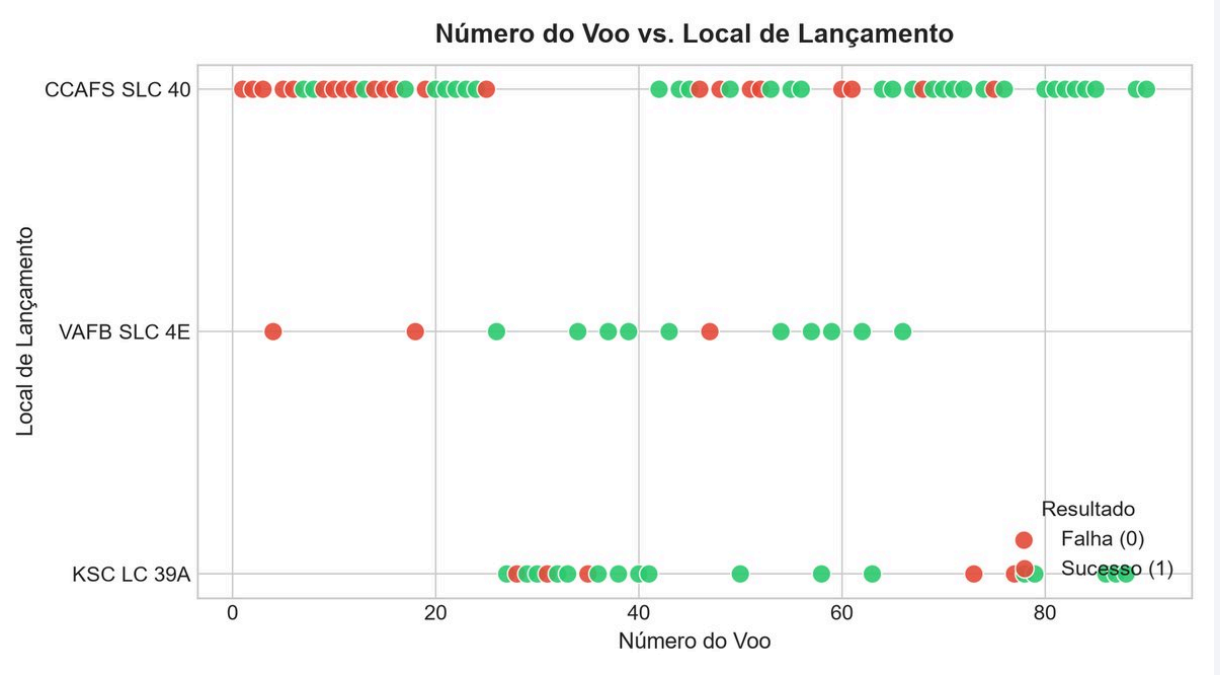
Section 2

Insights drawn from EDA

Número do Voo vs. Local de Lançamento

O que o gráfico mostra

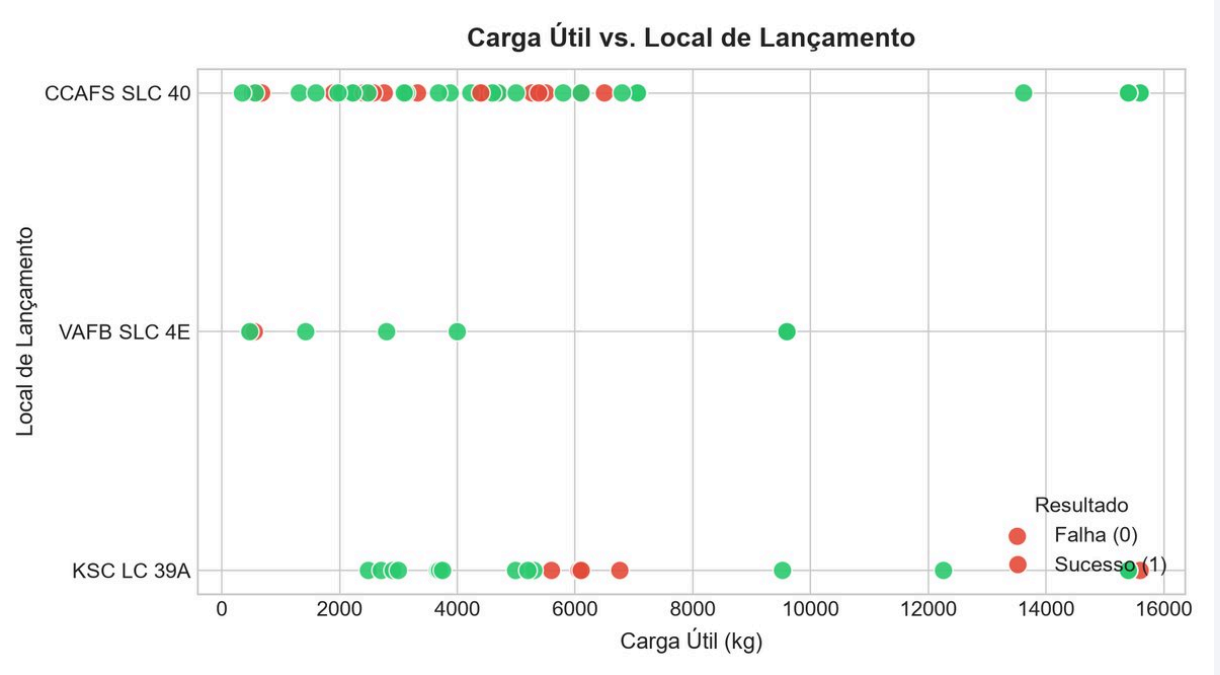
- Nos três locais, a proporção de pousos bem-sucedidos (Class = 1) cresce à medida que o número do voo aumenta
- CCAFS SLC-40 concentra o maior número de lançamentos
- Os primeiros voos têm mais falhas; os mais recentes, mais sucessos



Carga Útil vs. Local de Lançamento

O que o gráfico mostra

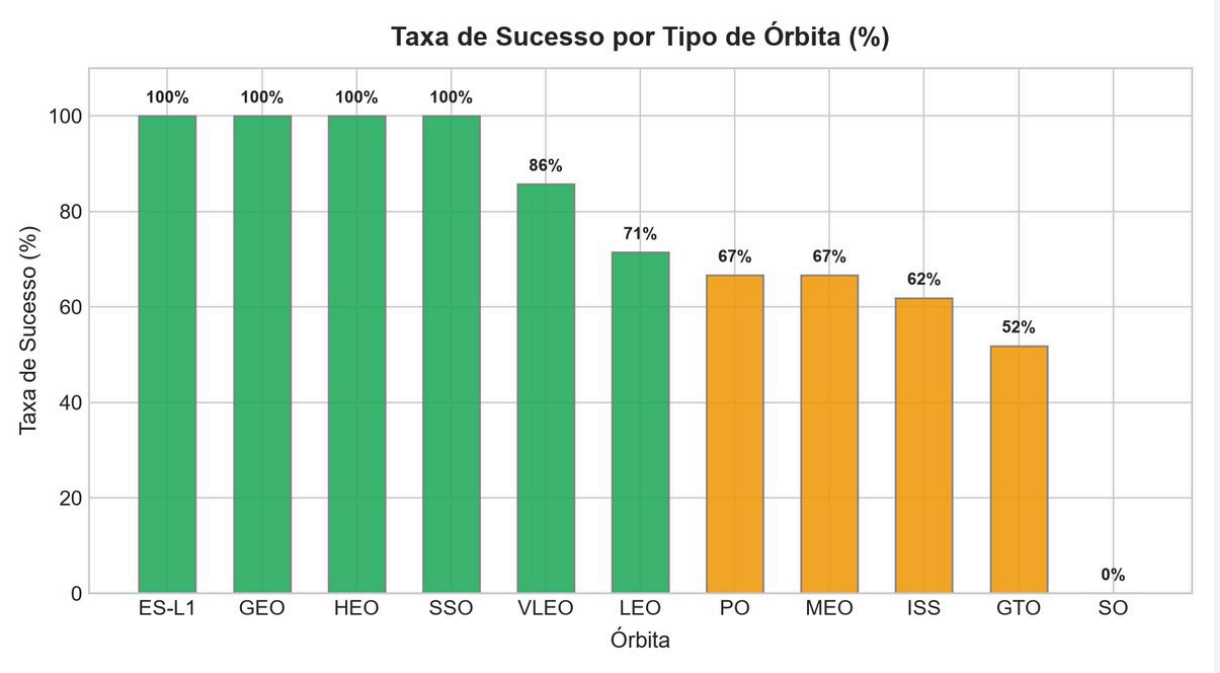
- VAFB SLC-4E não teve lançamentos com carga acima de 10.000 kg
- Em CCAFS e KSC LC-39A, as cargas pesadas têm boa proporção de pousos bem-sucedidos
- A carga útil, sozinha, não define o sucesso do pouso



Taxa de Sucesso vs. Tipo de Órbita

O que o gráfico mostra

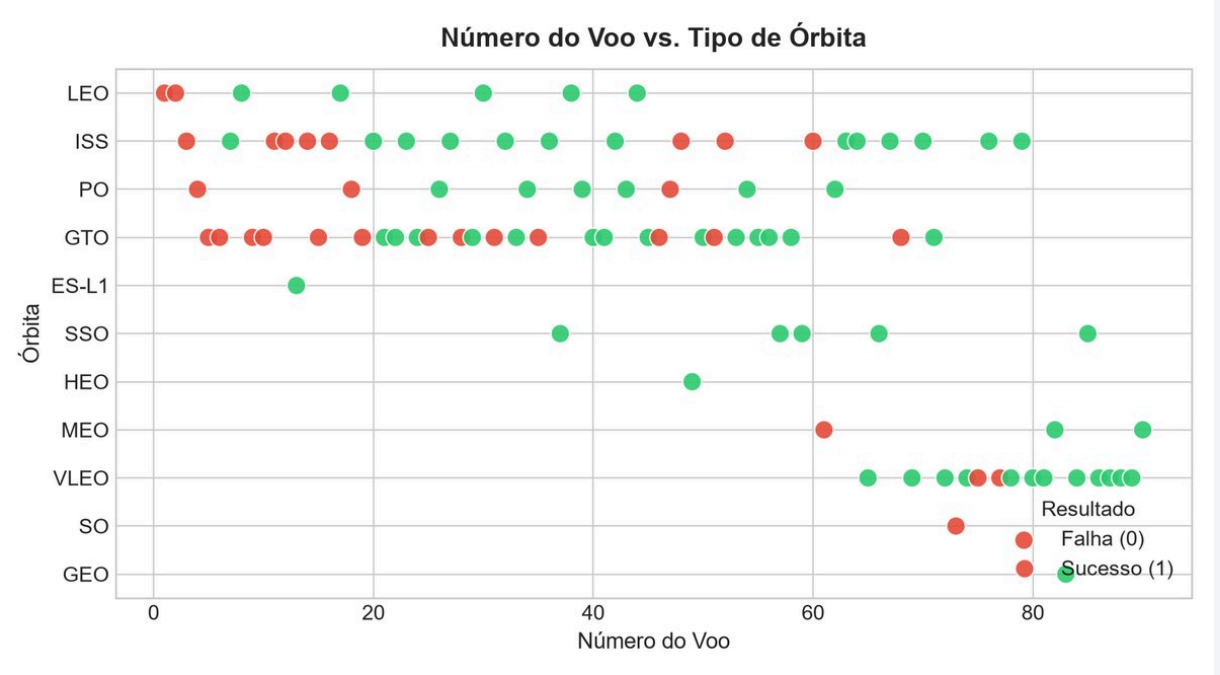
- ES-L1, GEO, HEO e SSO tiveram 100% de sucesso
- A órbita SO teve 0% de sucesso
- ES-L1, GEO e HEO têm apenas um voo cada, então a taxa pode ser enganosa



Número do Voo vs. Tipo de Órbita

O que o gráfico mostra

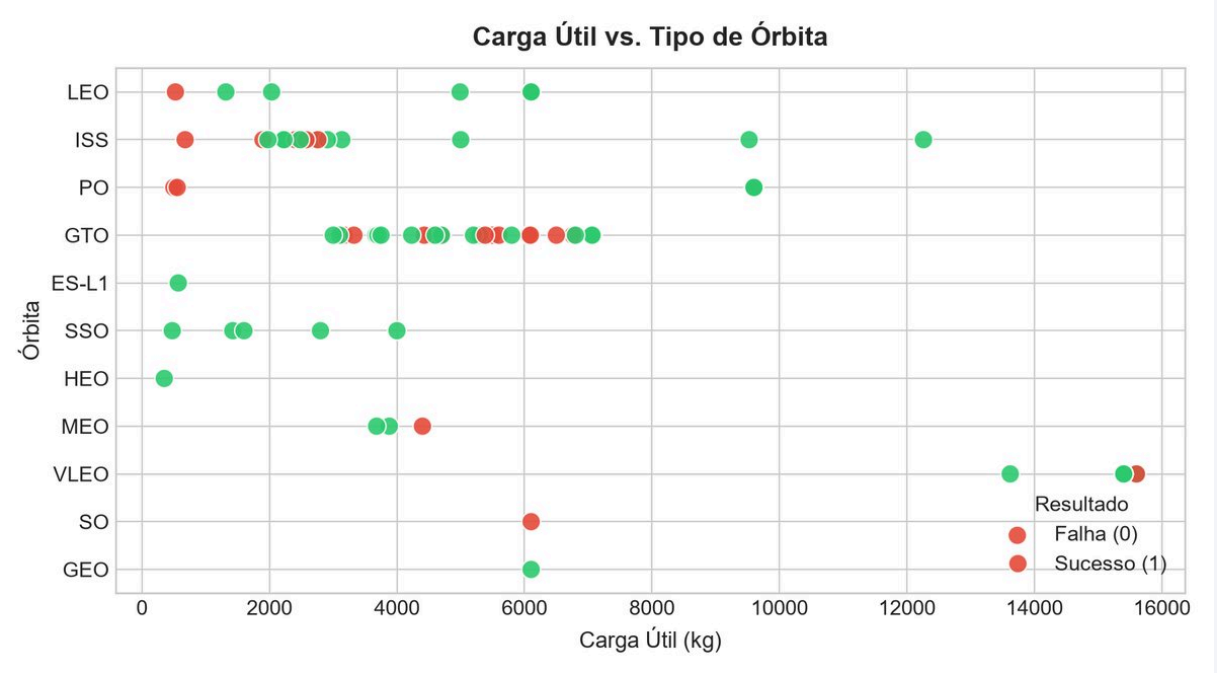
- Em LEO, o sucesso parece estar ligado ao número de voos
- Em GTO, não há relação clara entre número de voos e sucesso
- Órbitas mais recentes concentram os voos com pouso bem-sucedido



Carga Útil vs. Tipo de Órbita

O que o gráfico mostra

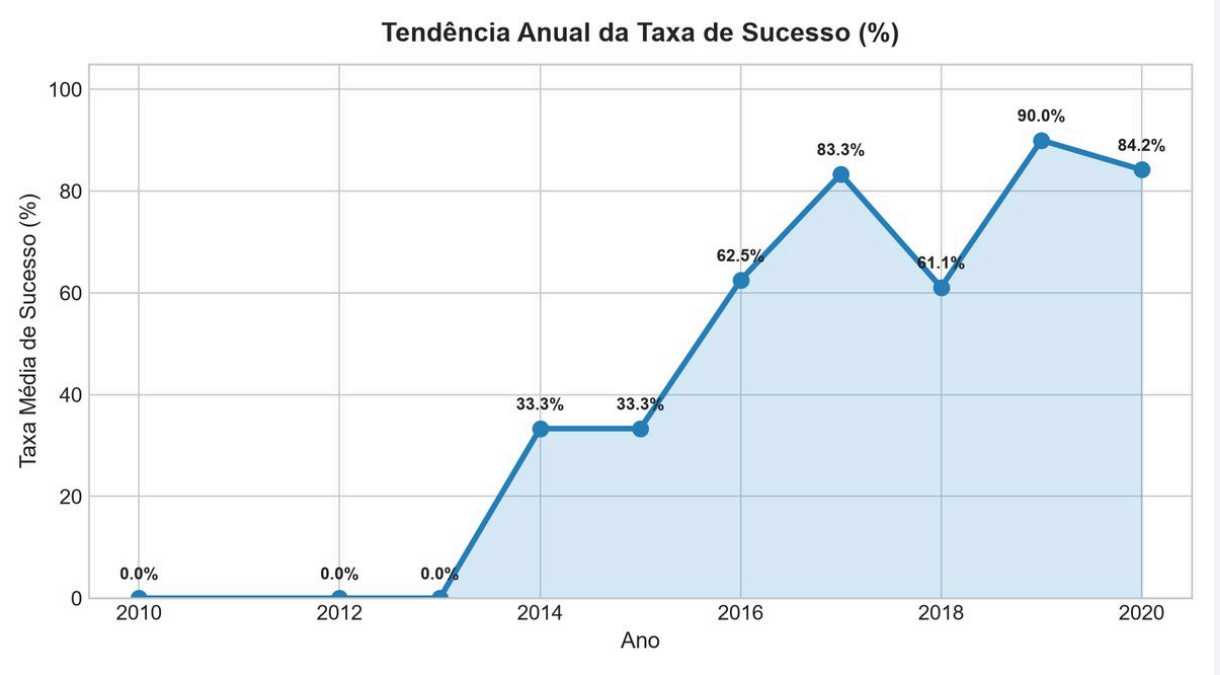
- Com cargas pesadas, os pousos bem-sucedidos são mais frequentes em PO, LEO e ISS
- Em GTO, é difícil separar sucessos e falhas, pois os dois resultados se misturam



Tendência Anual da Taxa de Sucesso

O que o gráfico mostra

- A taxa média de sucesso cresce desde 2013, com oscilações pontuais
- Reflete a experiência acumulada da SpaceX com o pouso e a reutilização dos boosters



Nomes dos Locais de Lançamento

Consulta SQL

```
SELECT DISTINCT Launch_Site
FROM SPACEXTABLE;
```

Resultado

Launch_Site
CCAFS LC-40
VAFB SLC-4E
KSC LC-39A
CCAFS SLC-40

DISTINCT remove repetições e retorna os 4 nomes de locais. CCAFS LC-40 e CCAFS SLC-40 são o mesmo complexo, registrado com nomes diferentes.

Locais que Começam com 'CCA'

Consulta SQL

```
SELECT * FROM SPACEXTABLE
WHERE Launch_Site LIKE 'CCA%' LIMIT 5;
```

Resultado

Data	Booster	Local	Carga	Massa (kg)	Cliente	Resultado
2010-06-04	F9 v1.0 B0003	CCAFS LC-40	Dragon Qualification Unit	0	SpaceX	Failure (parachute)
2010-12-08	F9 v1.0 B0004	CCAFS LC-40	Dragon demo flight C1	0	NASA (COTS)	Failure (parachute)
2012-05-22	F9 v1.0 B0005	CCAFS LC-40	Dragon demo flight C2	525	NASA (COTS)	No attempt
2012-10-08	F9 v1.0 B0006	CCAFS LC-40	SpaceX CRS-1	500	NASA (CRS)	No attempt
2013-03-01	F9 v1.0 B0007	CCAFS LC-40	SpaceX CRS-2	677	NASA (CRS)	No attempt

LIKE com o curinga % filtra os locais que começam com "CCA"; LIMIT 5 retorna só os cinco primeiros registros.

Carga Útil Total (NASA)

Consulta SQL

```
SELECT SUM(PAYLOAD_MASS__KG_) AS total_kg
FROM SPACEXTABLE
WHERE Customer = 'NASA (CRS)';
```

Resultado

total_kg
45.596

SUM soma a massa das cargas dos lançamentos feitos para a NASA (CRS): 45.596 kg no total.

Carga Útil Média do Booster F9 v1.1

Consulta SQL

```
SELECT AVG(PAYLOAD_MASS__KG_) AS media_kg
FROM SPACEXTABLE
WHERE Booster_Version = 'F9 v1.1';
```

Resultado

media_kg
2.928,4

AVG calcula a média da carga transportada pelo booster F9 v1.1: cerca de 2.928 kg.

Primeiro Pouso Bem-Sucedido em Terra

Consulta SQL

```
SELECT MIN(Date) AS primeira_data
FROM SPACEXTABLE
WHERE Landing_Outcome = 'Success (ground pad)';
```

Resultado

primeira_data
2015-12-22

MIN retorna a data mais antiga com pouso bem-sucedido em solo: 22 de dezembro de 2015.

Pouso em Drone Ship (Carga 4.000–6.000 kg)

Consulta SQL

```
SELECT DISTINCT Booster_Version FROM SPACEXTABLE
WHERE Landing_Outcome = 'Success (drone ship)'
  AND PAYLOAD_MASS__KG_ > 4000 AND PAYLOAD_MASS__KG_ < 6000;
```

Resultado

Booster_Version
F9 FT B1022
F9 FT B1026
F9 FT B1021.2
F9 FT B1031.2

Quatro boosters F9 FT pousaram em drone ship com cargas acima de 4.000 kg e abaixo de 6.000 kg.

Resultados das Missões: Sucesso e Falha

Consulta SQL

```
SELECT Mission_Outcome, COUNT(*) AS total
FROM SPACEXTABLE
GROUP BY Mission_Outcome;
```

Resultado

Mission_Outcome	total
Success	98
Success (payload status unclear)	1
Failure (in flight)	1

GROUP BY agrupa por resultado e COUNT conta as missões: quase todas tiveram sucesso e houve apenas uma falha em voo.

Boosters com a Carga Máxima

Consulta SQL

```
SELECT DISTINCT Booster_Version FROM SPACEXTABLE
WHERE PAYLOAD_MASS__KG_ = (SELECT MAX(PAYLOAD_MASS__KG_)
                           FROM SPACEXTABLE);
```

Resultado

Booster_Version		
F9 B5 B1048.4	F9 B5 B1049.4	F9 B5 B1051.3
F9 B5 B1056.4	F9 B5 B1048.5	F9 B5 B1051.4
F9 B5 B1049.5	F9 B5 B1060.2	F9 B5 B1058.3
F9 B5 B1051.6	F9 B5 B1060.3	F9 B5 B1049.7

A subconsulta encontra a carga máxima (15.600 kg); a consulta externa lista os 12 boosters da versão B5 que a transportaram.

Lançamentos de 2015

Consulta SQL

```
SELECT substr(Date, 6, 2) AS mes, Landing_Outcome, Booster_Version, Launch_Site
FROM SPACEXTABLE
WHERE Landing_Outcome = 'Failure (drone ship)' AND substr(Date, 1, 4) = '2015';
```

Resultado

mês	Landing_Outcome	Booster_Version	Launch_Site
01	Failure (drone ship)	F9 v1.1 B1012	CCAFS LC-40
04	Failure (drone ship)	F9 v1.1 B1015	CCAFS LC-40

Em 2015 houve duas falhas de pouso em drone ship (janeiro e abril), ambas com boosters F9 v1.1 lançados de CCAFS LC-40.

Ranking dos Resultados de Pouso (2010–2017)

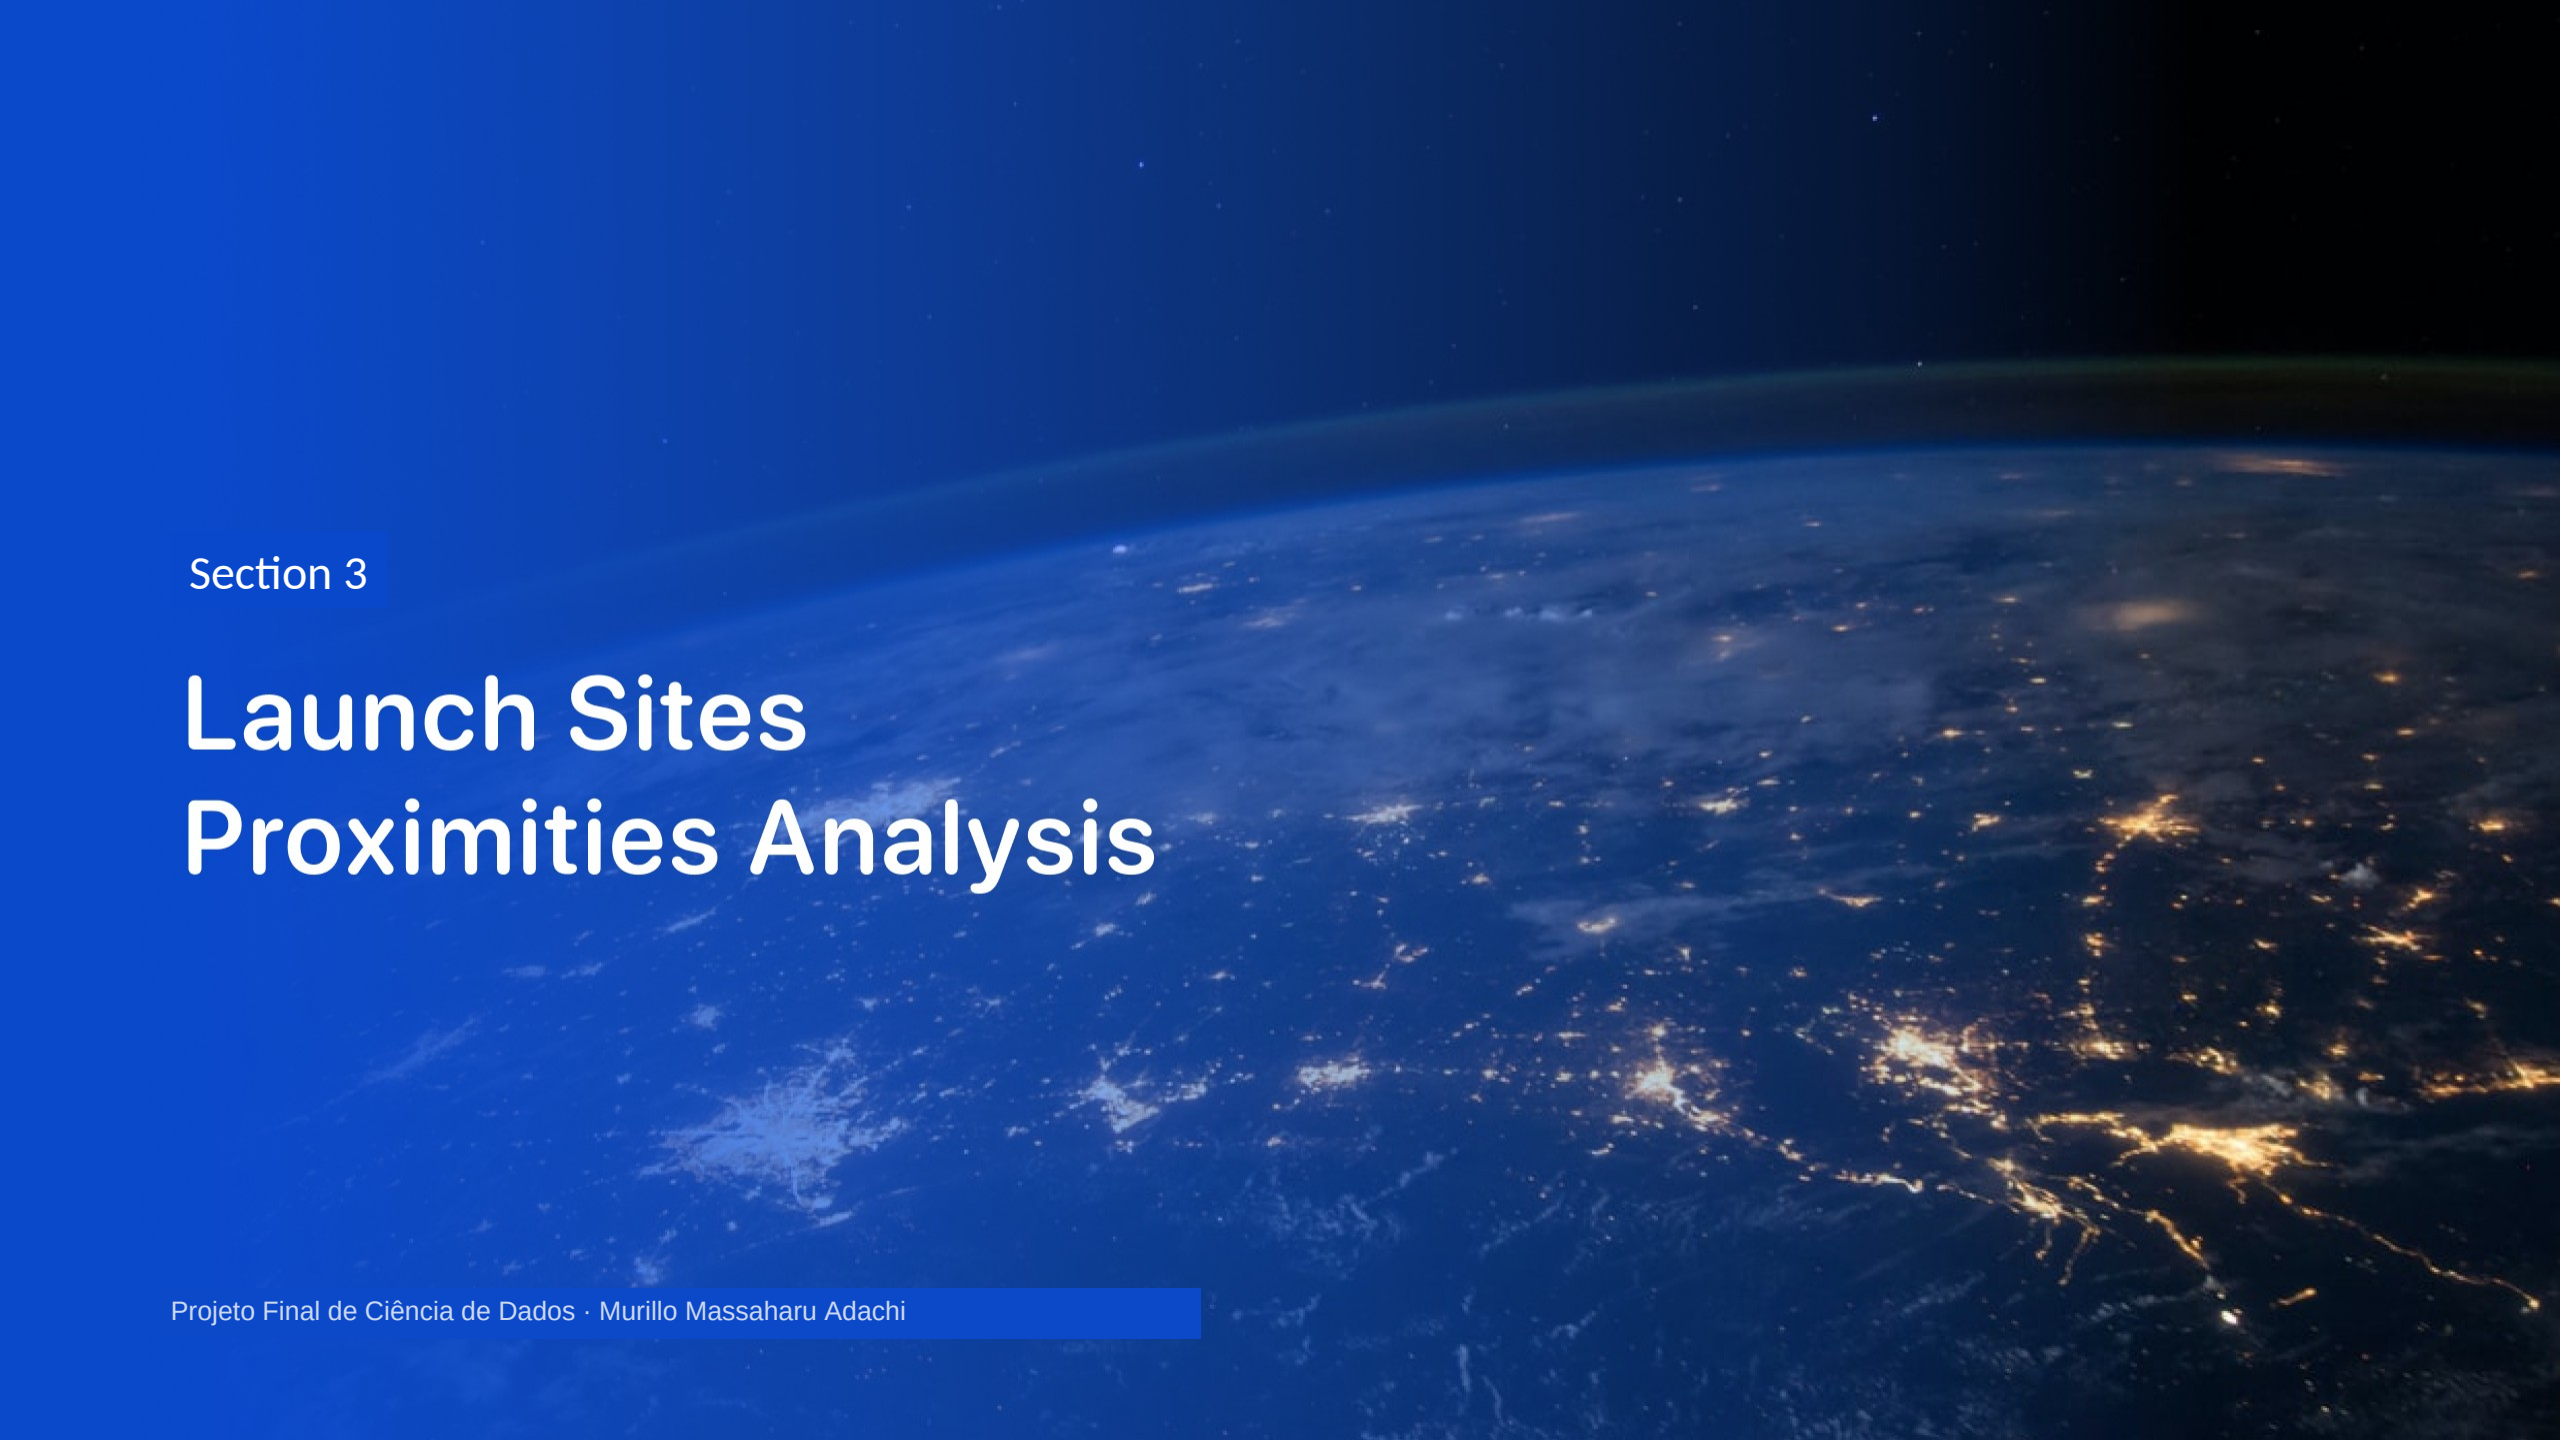
Consulta SQL

```
SELECT Landing_Outcome, COUNT(*) AS total
FROM SPACEXTABLE
WHERE Date BETWEEN '2010-06-04' AND '2017-03-20'
GROUP BY Landing_Outcome
ORDER BY total DESC;
```

Resultado

Landing_Outcome	total
No attempt	10
Success (drone ship)	5
Failure (drone ship)	5
Success (ground pad)	3
Controlled (ocean)	3
Uncontrolled (ocean)	2
Failure (parachute)	2

O ranking mostra que, no período, a maioria dos lançamentos não tentou pouso; entre as tentativas, pousos bem-sucedidos em drone ship e falhas empatam.



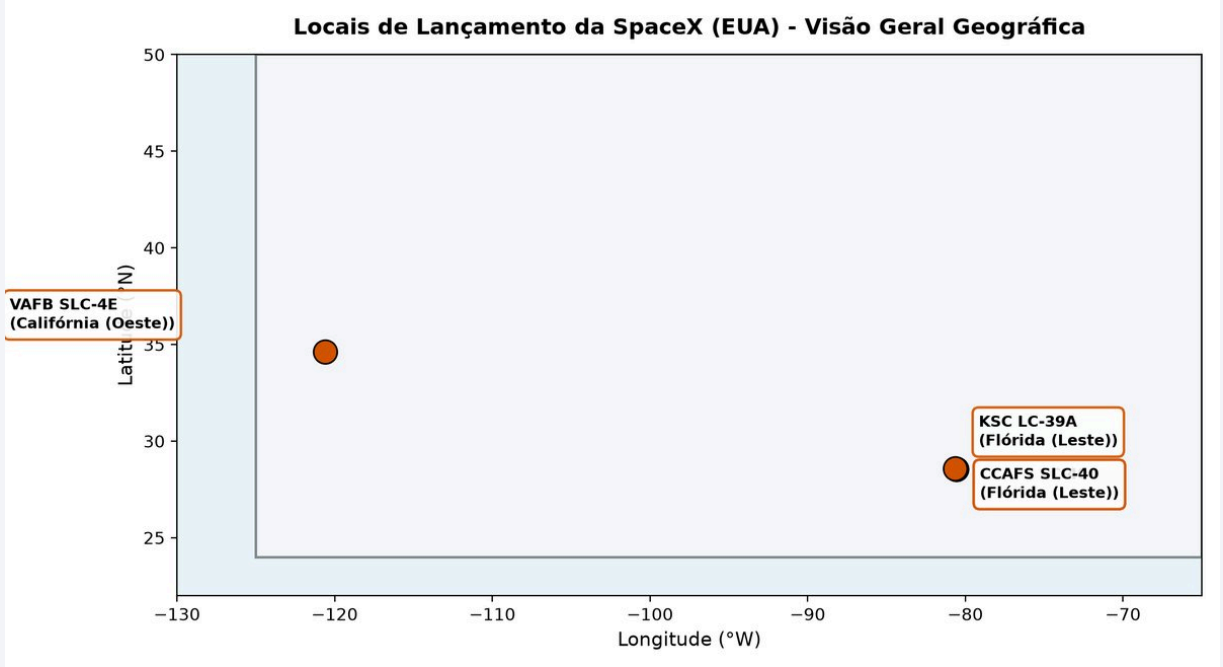
Section 3

Launch Sites Proximities Analysis

Locais de Lançamento no Mapa Global

Principais elementos

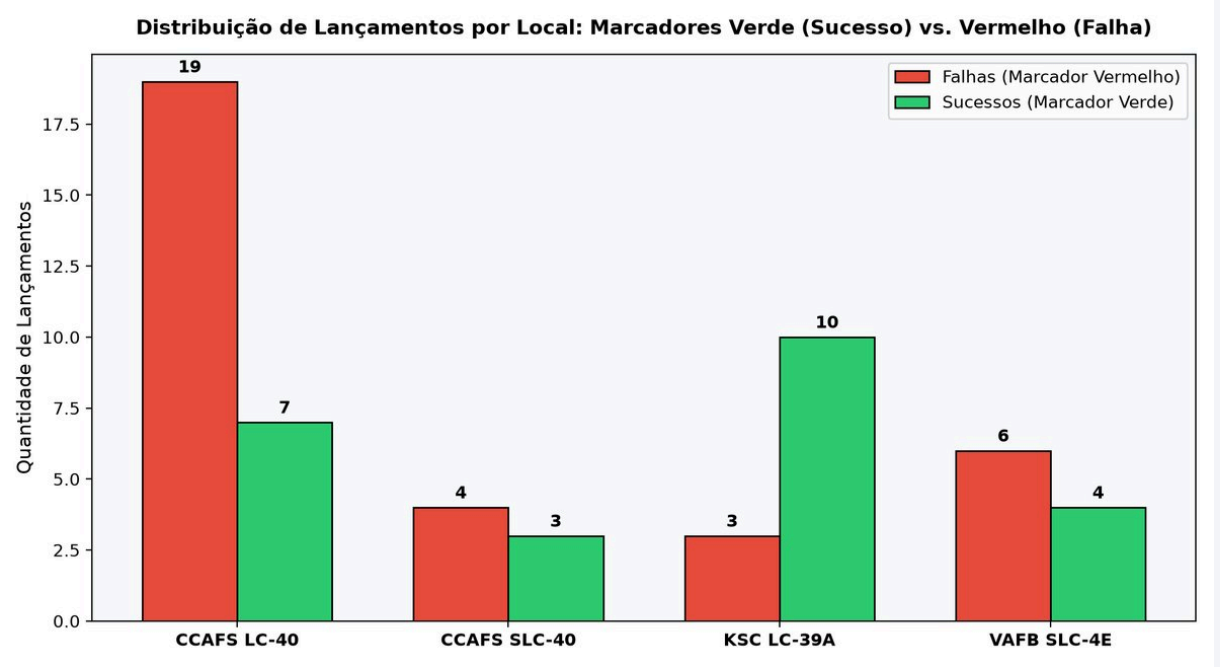
- Os quatro locais ficam nos EUA: três na Flórida e um na Califórnia
- Todos estão perto da costa, o que permite lançar sobre o oceano
- Os locais da Flórida estão mais próximos do Equador, onde a rotação da Terra ajuda o lançamento



Resultados dos Lançamentos por Local

Principais elementos

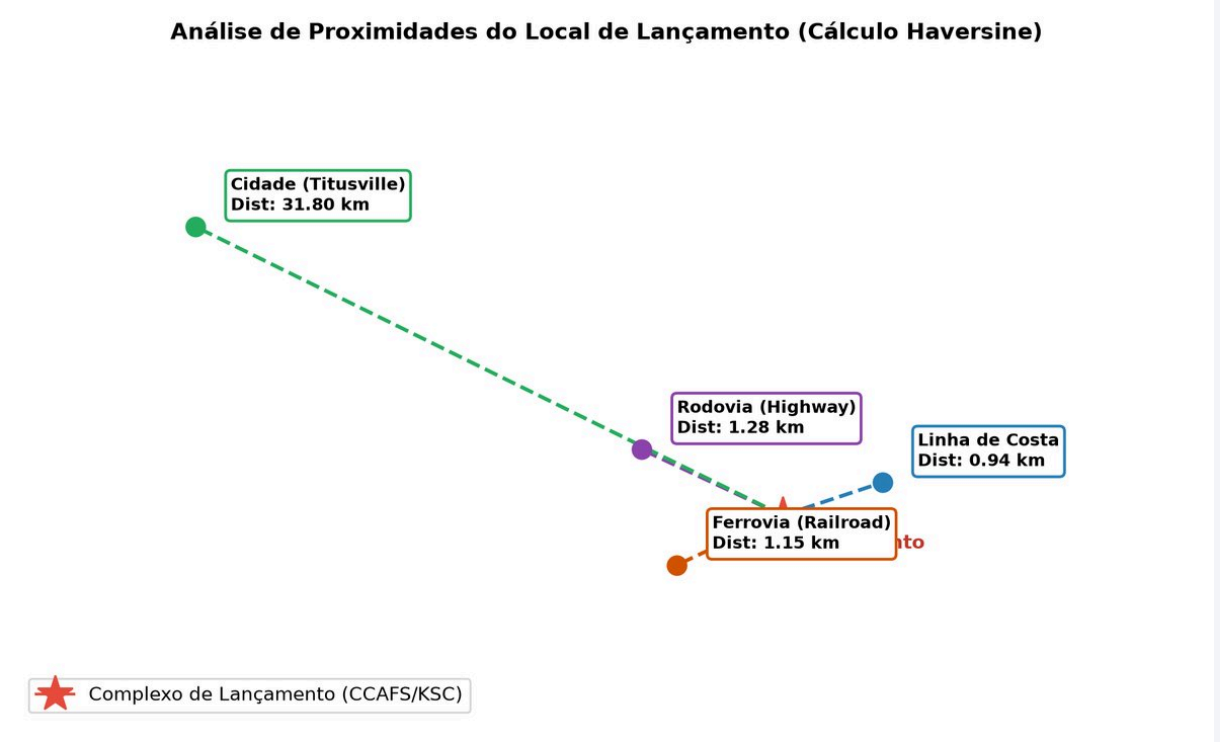
- Marcadores verdes indicam lançamentos com sucesso e vermelhos, falhas
- KSC LC-39A mostra a maior proporção de marcadores verdes
- CCAFS LC-40 concentra muitos marcadores vermelhos



Proximidades do Local de Lançamento

Principais elementos

- As linhas ligam o local à costa, à ferrovia, à rodovia e à cidade mais próxima, com a distância exibida
- Os locais ficam perto de costa, ferrovia e rodovia, o que facilita a logística
- Ficam longe de cidades, o que aumenta a segurança



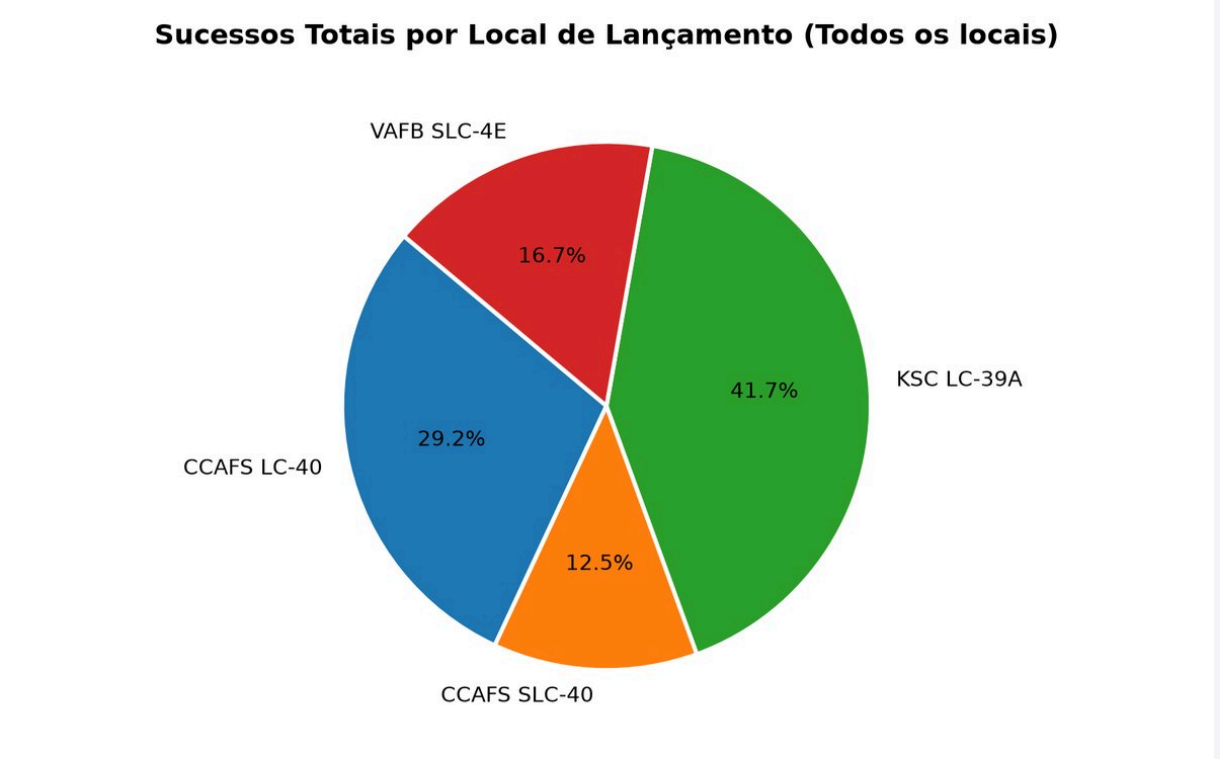
Section 4

Build a Dashboard with Plotly Dash

Sucessos por Local de Lançamento

Principais elementos

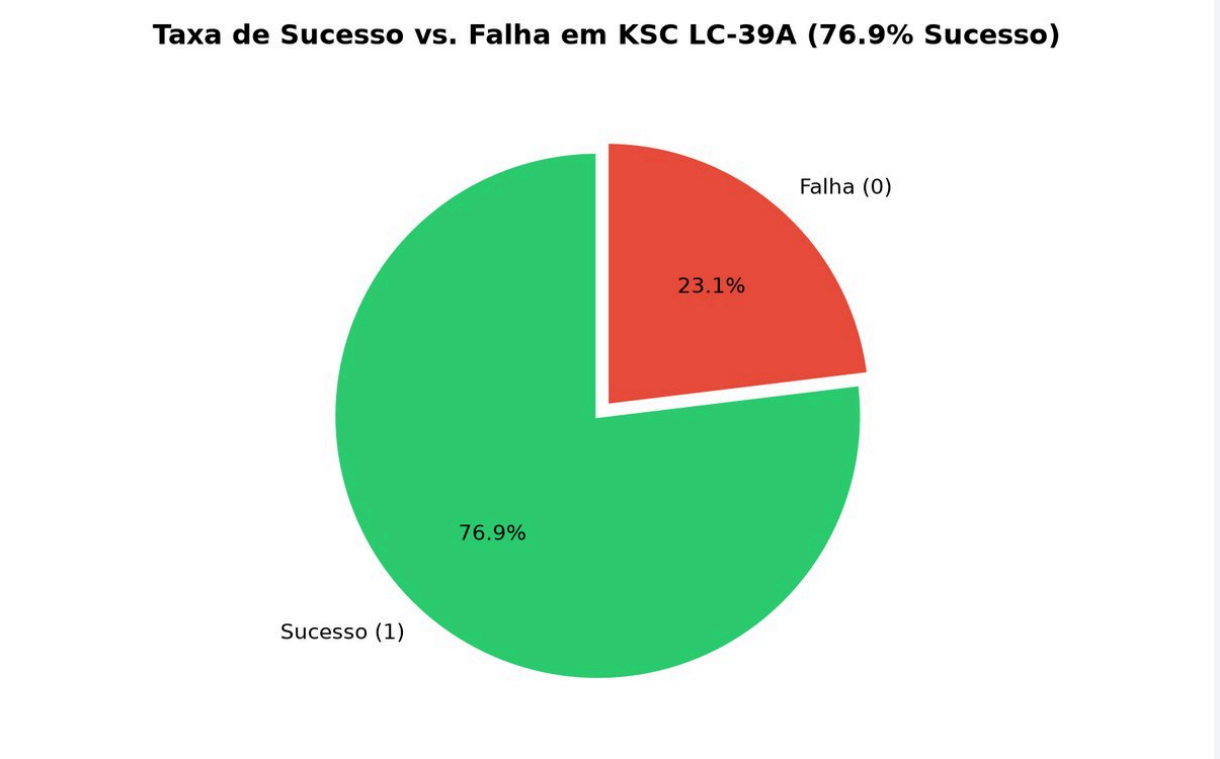
- O gráfico de pizza mostra a participação de cada local nos pousos bem-sucedidos
- KSC LC-39A concentra a maior fatia dos sucessos
- CCAFS SLC-40 tem a menor fatia



Local com Maior Taxa de Sucesso

Principais elementos

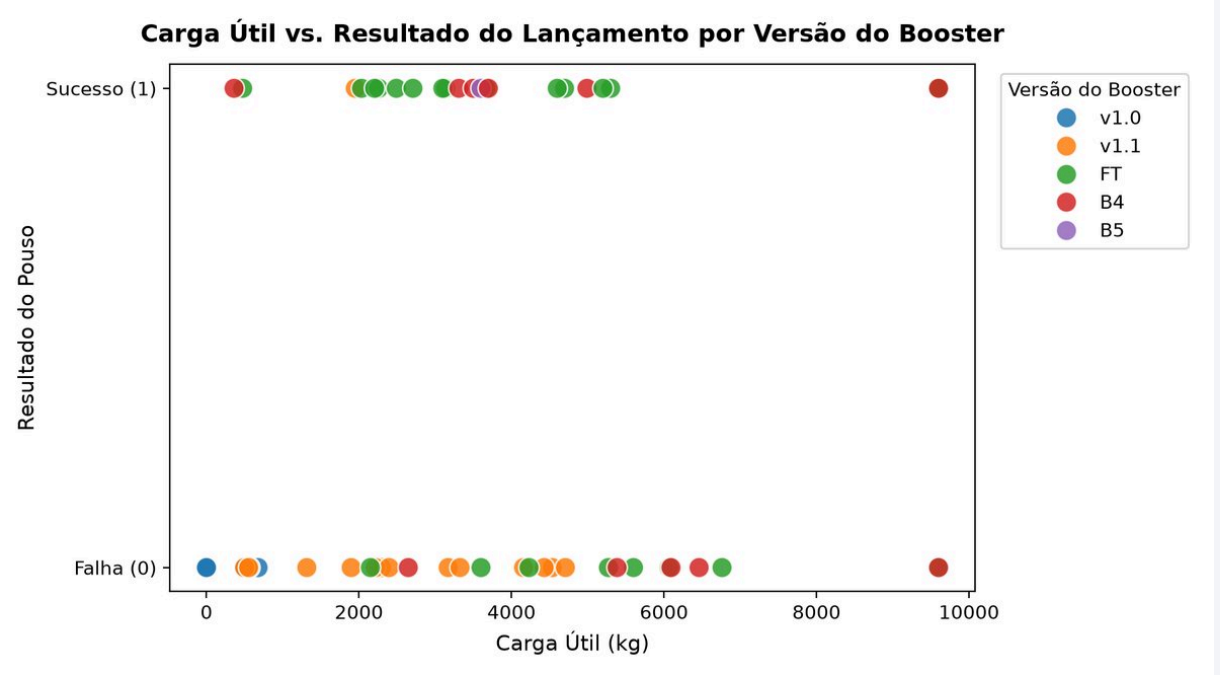
- KSC LC-39A tem a maior razão de sucesso: 76,9% (10 de 13 lançamentos)
- A pizza compara a fatia de sucessos e de falhas desse local



Carga Útil vs. Resultado do Lançamento

Principais elementos

- Cargas leves e médias (cerca de 2.000 a 5.500 kg) têm a maior taxa de sucesso
- O booster F9 FT (Full Thrust) concentra mais sucessos; o v1.1 tem poucos
- O slider permite comparar faixas de carga, para todos os locais ou para um local



Section 5

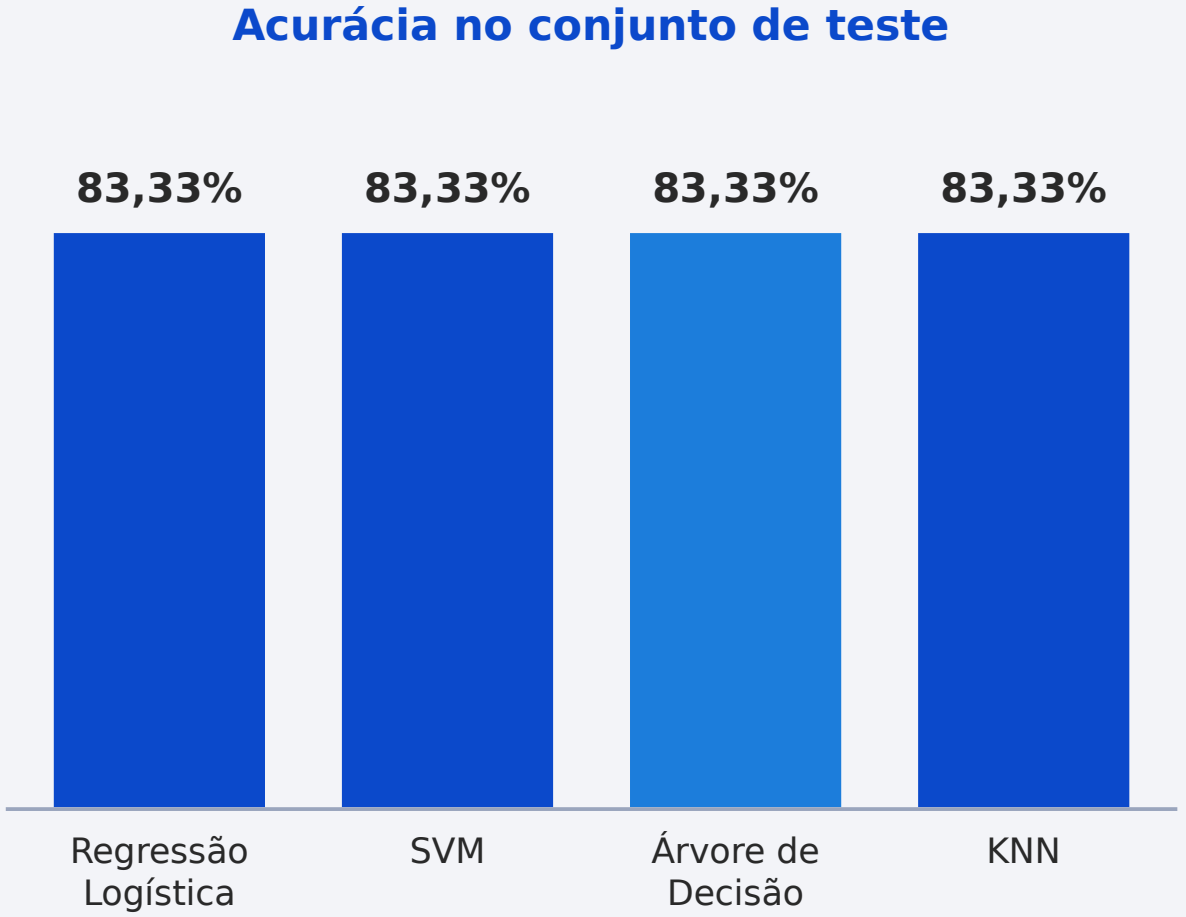
Predictive Analysis (Classification)



Acurácia dos Modelos de Classificação

Comparação dos modelos

- Os quatro modelos foram avaliados no mesmo conjunto de teste (18 lançamentos)
- Todos empataram em 83,33% de acurácia
- No desempate pela validação cruzada (GridSearchCV), a Árvore de Decisão teve o melhor score



Matriz de Confusão

	Previsto: não pousou	Previsto: pousou
Real: não pousou	3	3
Real: pousou	0	12

Matriz do melhor modelo no conjunto de teste (18 lançamentos).

Como ler a matriz

- O modelo acerta todos os pousos bem-sucedidos (12 de 12)
- Erra 3 falhas, classificadas como sucesso (falsos positivos)
- Precisão de 80% e recall de 100% para a classe "pousou"

Conclusões

- A taxa de sucesso do pouso aumenta com o número de voos e ao longo dos anos
- KSC LC-39A é o local com maior taxa de sucesso entre os locais de lançamento
- Órbitas ES-L1, GEO, HEO e SSO tiveram 100% de sucesso, mas com poucas amostras
- Os locais ficam perto da costa e longe de cidades, com acesso a ferrovias e rodovias
- Os modelos preveem o pouso com cerca de 83% de acurácia, útil para estimar o custo do lançamento

66,7%

de sucesso nos pousos do dataset (60 de 90)

83,3%

de acurácia dos modelos no conjunto de teste

Visão Executiva em Uma Página

66,7%
dos pousos do dataset foram bem-sucedidos

76,9%
de sucesso no KSC LC-39A, o melhor local

83,3%
de acurácia na previsão do pouso

Por que importa

- A reutilização do primeiro estágio explica o preço: cerca de US$ 62 milhões contra mais de US$ 165 milhões
- Prever o pouso permite estimar o custo de um lançamento

O que recomendamos

- Usar o modelo como apoio à decisão, não como resposta única
- Priorizar locais e órbitas com histórico mais forte
- Ampliar a base de dados antes de decidir

Ideias Inovadoras e Próximos Passos

Simulador de custo	Combina a probabilidade de pouso (predict_proba) com o preço do lançamento para estimar o custo esperado de cada missão
Novas variáveis	Clima, vento, janela de lançamento, idade e reuso do núcleo para melhorar a previsão
Modelo explicável	Importância das variáveis e curvas de calibração para justificar cada previsão
Painel sempre atualizado	Coleta automática pela API e retreino periódico do modelo
Mais dados e validação	São só 90 lançamentos: validação cruzada repetida e novos lançamentos reduzem o risco de excesso de ajuste

Repositório no GitHub

Repositório: **https://github.com/mmadachi/capstone-spacex**

```
capstone-spacex/
├── README.md
├── notebooks/
│   ├── 01_coleta_api_spacex.ipynb
│   ├── 02_coleta_web_scraping.ipynb
│   ├── 03_data_wrangling.ipynb
│   ├── 04_eda_sql.ipynb
│   ├── 05_eda_visualizacao.ipynb
│   ├── 06_mapa_folium.ipynb
│   └── 07_classificacao.ipynb
├── dashboard/spacex_dash_app.py
└── apresentacao/  (PDF final)
```

Como consultar

- Notebooks com código e saídas visíveis
- Dashboard em Python (Dash)
- README com instruções de execução
- PDF da apresentação na pasta apresentacao

Apêndice

Criação da variável-alvo (Class)

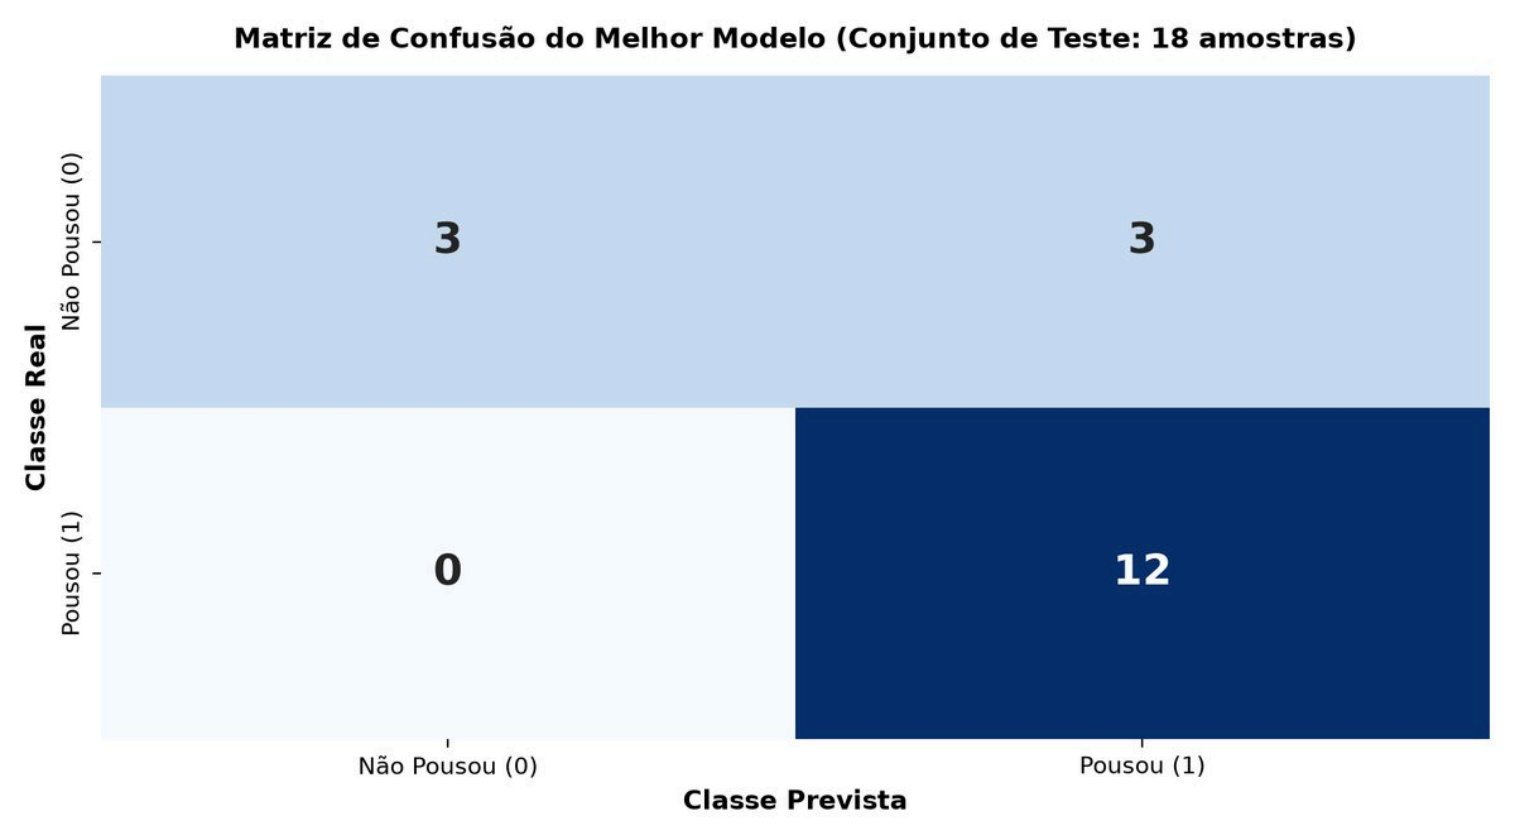
```
bad = {"False Ocean", "False RTLS",
       "False ASDS", "None ASDS",
       "None None"}
df["Class"] = df["Outcome"].apply(
    lambda x: 0 if x in bad else 1)
df["Class"].mean()  # ~0,667
```

Ajuste de hiperparâmetros

```
gscv = GridSearchCV(model,
                    parameters, cv=10)
gscv.fit(X_train, Y_train)
print(gscv.best_params_)
print(gscv.best_score_)
print(gscv.score(X_test, Y_test))
```

Os trechos acima resumem as etapas centrais do projeto. Gráficos e tabelas adicionais, não utilizados nos slides anteriores, estão no slide seguinte.

Apêndice – Materiais Adicionais



Thank you!

